



ikanamRAG

Наилучшее исследование священной группы ИКАНАМА

Москва 2025



Команда



Хамади
Алина



Терентьева
Лилия



Попов
Владислав




Косован
Дарья




Смирнов
Сергей


С чего всё началось




1 стадия - отрицание




2 стадия - гнев



3 стадия - торг




4 стадия - депрессия



5 стадия - принятие

Начало работы

Мы разделили проект на 5 этапов



- Каждый этап представляет собой практическую часть в виде написания кода Python, а также теоретическую часть в виде объяснения хода решения
- Проект был выполнен командой №9, включающая 5 умнейших гениев, для каждого поровну были распределены задачи и была своя зона ответственности

1 этап (Датасет)

Шаги реализации:

1. **Авторизация в VK API**
 - Получение токена доступа
 - Определение ID сообщества (groups.getById)
2. **Сбор постов**
 - Использование метода wall.get с пагинацией
 - Обработка 100 постов за запрос + задержка 0.34 сек
3. **Сбор комментариев**
 - Для каждого поста запрос wall.getComments
 - Сохранение текста без метаданных пользователей
4. **Ручной сбор статей**
 - Экспорт материалов из раздела "Публикации"
5. **Объединение и очистка данных**
 - Формирование единого датафрейма
 - Замена пропущенных значений

criminal database



Необходимые библиотеки

- requests
- pandas
- time
- datetime
- load_dotenv
- os

Результаты 1 этапа

Полученный датасет:

- Посты: 1,035 записей (2016-2024)
- Комментарии: 2,647 ответов
- Статьи: 9 материалов

Структура данных:

python

```
{  
  'post_id': 5836,  
  'date': '2025-03-25',  
  'text': 'ХОБА, ВЕСЕННИЙ ЛОФТ!...',  
  'type': 'пост',  
  'source': 'vk.com/wall-130344439_5836'  
}
```



Когда увидел наш датасет

2 этап (Предобработка)

Шаги реализации:

1. **Удаление HTML-тегов и спецсимволов**
 - Использование BeautifulSoup для очистки от html-разметки
 - Удаление технических и декоративных символов (например, стрелок, маркеров, эмодзи)
2. **Очистка от URL и ссылок**
 - Регулярные выражения для удаления всех видов ссылок (http, https) из текста
3. **Удаление лишних пробелов и переносов строк**
 - Нормализация текста для удобства дальнейшей обработки: удаление многократных пробелов, табуляций, переходов строк
4. **Удаление повторов и пустых строк**
 - Фильтрация дублирующихся или пустых фрагментов текста для улучшения качества данных
5. **Финальная нормализация**
 - Приведение текста к единому формату (например, строчные буквы, базовые знаки препинания)



Необходимые библиотеки

- pandas
- re
- BeautifulSoup

Результаты 2 этапа

- Тексты очищены от html, ссылок и технических символов, что повысило читаемость и качество данных
- Исключены повторы и «шум» — обеспечена уникальность смысловых фрагментов
- Подготовлены чистые тексты для автоматического разбиения на смысловые чанки
- Повышена корректность и точность последующего анализа и извлечения знаний
- Создан надежный базис для построения тематического корпуса и интеграции в RAG-систему



**Завалить всех на
теории андана**



**завалить всех на вопросе
«какое у меня отчество?»**

3 этап (Деление на чанки и структурирование)

Шаги реализации:

1. **Выбор инструмента для разбиения**
 - Использование RecursiveCharacterTextSplitter из библиотеки LangChain
2. **Автоматическое разбиение текстов**
 - Обработка каждого документа (поста или статьи) на логические смысловые блоки
3. **Присвоение уникальных идентификаторов чанкам**
 - Формирование пары (document_id, chunk_id) для однозначной идентификации каждого фрагмента
4. **Сохранение метаданных и источников**
 - Связь чанков с исходными заголовками, типом контента и ссылками на публикации
5. **Формирование итогового структурированного датасета**
 - Табличное хранение с колонками: document_id, chunk_id, title, chunk_text, source, content_type

программист



нееет ты не можешь просто
взять и сломать мой сайт.
Я отучился в ВУЗе 4 года,
мой код прошел все стадии
тестирования, он полностью
безопасен неееет

случайный
студент



МОГУ.

Необходимые библиотеки

- pandas
- re
- RecursiveCharacterTextSplitter
- matplotlib.pyplot
- SentenceTransformer
- faiss
- numpy

Результаты 3 этапа

- Длинные тексты успешно разбиты на смысловые фрагменты размером 300–500 символов с перекрытием
- Обеспечена сохранность контекста и логики за счет рекурсивного разбиения
- Каждый чанк снабжен уникальным идентификатором для удобства поиска и анализа
- Получен структурированный корпус, готовый для интеграции в интеллектуальные ассистенты и RAG-системы
- Улучшена масштабируемость и качество обработки больших объемов текстов сообщества Иканам



4 этап (Визуализация на Streamlit)

Шаги реализации:

1. Создание простого веб-приложения с использованием Streamlit.
2. Загрузка и кэширование подготовленного датасета чанков.
3. Реализация фильтров по типу контента (пост/статья) и диапазону годов.
4. Визуализация динамики публикаций по годам и распределения длины чанков.
5. Построение тематического облака ключевых слов и отображение топ-частот.
6. Организация интерактивной таблицы с возможностью поиска и просмотра источников.
7. Реализация функции поиска по тексту с использованием эмбедингов и FAISS.



Необходимые библиотеки

- streamlit
- pandas
- matplotlib.pyplot
- seaborn
- WordCloud, Counter, re, faiss, numpy, SentenceTransformer, Image

Результаты 4 этапа


- Создано удобное веб-приложение для анализа корпуса текстов сообщества Иканам.
- Пользователи могут фильтровать данные по году, типу контента и ключевым словам.
- Визуализация позволяет быстро оценить динамику публикаций и популярные темы.
- Тематическое облако и топ-частотные слова помогают выявить ключевые направления.
- Поиск по текстам чанков с помощью векторных эмбедингов улучшает качество результатов.
- Интерактивная таблица облегчает работу с большим объёмом данных и доступ к источникам.



5 этап (Поиск зависимостей)

Шаги реализации:

1. Формулировка и выбор гипотез для проверки на основе данных корпуса
2. Анализ корреляций между ключевыми показателями (например, объем публикаций и тематические частоты)
3. Использование статистических методов и визуализаций для выявления закономерностей
4. Исследование временных трендов и их влияния на содержание публикаций
5. Интерпретация результатов и проверка значимости обнаруженных зависимостей




Необходимые библиотеки



- pandas
- matplotlib

Результаты 5 этапа

- Выявлены значимые корреляции между количеством публикаций и популярностью ключевых тем
- Обнаружены сезонные и годовые тренды в активности Иканама
- Подтверждены взаимосвязи между типом контента и длиной текстовых чанков
- Получены инсайты для дальнейшего углубленного анализа и настройки RAG-системы
- Результаты позволили уточнить направления для последующих исследований и улучшения модели



Результаты 5 этапа



Q&A

Благодарим за внимание

Москва 2025

